

Métodos Numéricos - Ajuste de Curvas

Ricardo Largaespada

31 de octubre de 2018

El ajuste de curvas se aplica a datos que contienen dispersión (ruido), generalmente debido a errores de medición. Aquí queremos encontrar una curva suave que aproxime los datos en algún sentido. Por lo tanto, la curva no tiene que pasar por los puntos de datos.

1. Regresión lineal

El ejemplo más simple de una aproximación por mínimos cuadrados es ajustar una línea recta a un conjunto de observaciones definidas por puntos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$.

La expresión matemática para la línea recta es

$$y = a_0 + a_1x + e$$

donde a_0 y a_1 son coeficientes que representan la intersección con el eje y y la pendiente, respectivamente, e es el error, o diferencia, entre el modelo y las observaciones, el cual se representa al reordenar la ecuación como

$$e = y - a_0 - a_1x.$$

Así, el *error* o *residuo* es la discrepancia entre el valor verdadero de y y el valor aproximado, $a_0 + a_1x$, que predijo la ecuación lineal.

La estrategia que supera las deficiencias de los procedimientos de minimizar la suma de los residuos, la suma de los valores absolutos de los residuos y minimizar el error máximo de cualquier punto individual consiste en minimizar la suma de los cuadrados de los residuos entre la y medida y la y calculada con el modelo lineal

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_{i,\text{medida}} - y_{i,\text{modelo}})^2 = \sum_{i=1}^n (y_i - a_0 - a_1x_i)^2$$

Este criterio tiene varias ventajas, entre ellas el hecho de que se obtiene una línea única para cierto conjunto de datos. Antes de analizar tales propiedades, presentaremos una técnica para determinar los valores de a_0 y a_1 que minimizan la suma de cuadrados de errores.

Para determinar los valores de a_0 y a_1 , derivamos con respecto a cada uno de los coeficientes¹

$$\begin{aligned}\frac{\partial S_r}{\partial a_0} &= -2 \sum (y_i - a_0 - a_1x_i) \\ \frac{\partial S_r}{\partial a_1} &= -2 \sum ([y_i - a_0 - a_1x_i]x_i)\end{aligned}$$

¹Las sumatorias van desde $i = 1$ hasta n .

Al igualar estas derivadas a cero, se dará como resultado un S_r mínimo². Si se hace esto, las ecuaciones se expresan como:

$$\begin{aligned} 0 &= \sum y_i - \sum a_0 - \sum a_1 x_i \\ 0 &= \sum x_i y_i - \sum a_0 x_i - \sum a_1 x_i^2 \end{aligned}$$

Ahora si observamos que $\sum a_0 = na_0$, expresamos las ecuaciones como un conjunto de dos ecuaciones lineales simultáneas, con dos incógnitas (a_1 y a_0):

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}$$

Si resolvemos de forma simultánea obtenemos que:

$$a_1 = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}$$

Para encontrar a_0 usamos la ecuación

$$a_0 = \bar{y} - a_1 \bar{x}$$

donde $\bar{y}$ y $\bar{x}$ son las medias de y y x , respectivamente.

Ejemplo 1.1. Ajusta una línea a los datos mostrados:

x	0.0	1.0	2.0	2.5	3.0
y	2.9	3.7	4.1	4.4	5.0

Los promedios de los datos son

$$\begin{aligned} \bar{x}_i &= \frac{1}{5} \sum x_i = \frac{0.0 + 1.0 + 2.0 + 2.5 + 3.0}{5} = 1.7 \\ \bar{y}_i &= \frac{1}{5} \sum y_i = \frac{2.9 + 3.7 + 4.1 + 4.4 + 5.0}{5} = 4.02 \end{aligned}$$

El intercepto a_0 y la pendiente a_1 de la línea de regresión pueden ser determinadas por:


$$\begin{aligned} a_1 &= \frac{\sum y_i (x_i - \bar{x})}{\sum x_i (x_i - \bar{x})} \\ &= \frac{2.9(-1.7) + 3.7(-0.7) + 4.1(0.3) + 4.4(0.8) + 5.0(1.3)}{0.0(-1.7) + 1.0(-0.7) + 2.0(0.3) + 2.5(0.8) + 3.0(1.3)} \\ &= \frac{3.73}{5.8} = 0.6431 \\ a_0 &= \bar{y} - \bar{x}a_1 = 4.02 - 1.7(0.6431) = 2.927 \end{aligned}$$

Entonces, la línea de regresión es $f(x) = 2.927 + 0.6431x$, la cual se muestra en la figura junto a los puntos.

²Ya que: $\frac{\partial^2 S_r}{\partial a_0^2} = 2n$, $\frac{\partial^2 S_r}{\partial a_1^2} = 2 \sum x_i^2$ y $\frac{\partial^2 S_r}{\partial a_1 \partial a_0} = 2 \sum x_i$, implicando que $\Delta = \frac{\partial^2 S_r}{\partial a_0^2} \cdot \frac{\partial^2 S_r}{\partial a_1^2} - \left(\frac{\partial^2 S_r}{\partial a_1 \partial a_0} \right)^2 = 4 \left(n \sum x_i^2 - (\sum x_i)^2 \right) \geq 0$ (Desigualdad de Cauchy-Schwarz)

y	2.900	3.700	4.100	4.400	5.000
$f(x)$	2.927	3.570	4.213	4.535	4.856
$y - f(x)$	-0.027	0.130	-0.113	-0.135	0.144
$y - \bar{y}$	-1.12	-0.320	0.080	0.380	0.980

Cuadro 1: Cálculos para el análisis de error en el ajuste lineal.



1.1. Cuantificación del error

Cualquier otra línea diferente a la calculada en el ejemplo 1.1 dará como resultado una suma mayor de los cuadrados de los residuos. Así, la línea es única y, en términos de nuestro criterio elegido, es la “mejor” línea a través de los puntos. Varias propiedades de este ajuste se observan al examinar más de cerca la forma en que se calcularon los residuos. Recuerde que la suma de los cuadrados se define como

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

El cuadrado del residuo representa el cuadrado de la distancia vertical entre el dato y otra medida de tendencia central³: la línea recta. La analogía se puede extender aún más en casos donde 1. la dispersión de los puntos alrededor de la línea es de magnitud similar en todo el rango de los datos, y 2. la distribución de estos puntos cerca de la línea es normal. Es posible demostrar que si estos criterios se cumplen, la regresión por mínimos cuadrados proporcionará la mejor estimación de a_0 y a_1 . Esto se conoce en estadística como el *principio de máxima verosimilitud*. Además si estos criterios se satisfacen, una “desviación estándar” para la línea de regresión se determina como sigue

$$S_{y/x} = \sqrt{\frac{S_r}{n-2}}$$

donde $S_{y/x}$ se le llama *error estándar del estimado*. El subíndice y/x designa que el error es para un valor predicho de y correspondiente a un valor particular de x . También, observe que

³Son medidas de tendencia central: la media aritmética, mediana, moda.

dividimos entre $n - 2$ debido a que se usaron 2 datos estimados (a_0 y a_1), para calcular S_r ; así se han perdido dos grados de libertad.

Así como en el caso de la desviación estándar, el error estándar del estimado cuantifica la dispersión de los datos. Aunque, $S_{y/x}$ cuantifica la dispersión alrededor de la línea de regresión, a diferencia de la desviación estándar original S_y que cuantifica la dispersión alrededor de la media.

Los conceptos anteriores se utilizan para cuantificar la “bondad” de nuestro ajuste.

Después de realizar la regresión, calculamos S_r , es decir, la suma de los cuadrados de los residuos alrededor de la línea de regresión. Esto caracteriza el error residual que queda después de la regresión. Es por lo que, algunas veces, se le llama la *suma inexplicable de los cuadrados*. La diferencia entre estas dos cantidades, $S_t - S_r$, cuantifica la mejora o reducción del error por describir los datos en términos de una línea recta en vez de un valor promedio⁴. Como la magnitud de esta cantidad depende de la escala, la diferencia se normaliza a S_t para obtener

$$r^2 = \frac{S_t - S_r}{S_t} \quad (1)$$

donde r^2 se conoce como el *coeficiente de determinación* y r es el coeficiente de correlación. En un ajuste perfecto, $S_r = 0$ y $r = r^2 = 1$, significa que la línea explica el 100 % de la variabilidad de los datos. Si $r = r^2 = 0$, $S_r = S_t$ el ajuste no presenta alguna mejora. Una representación alternativa para r que es más conveniente para implementarse en una computadora es

$$r = \frac{n \sum x_i y_i - (\sum x_i)(\sum y_i)}{\sqrt{n \sum x_i^2 - (\sum x_i)^2} \sqrt{n \sum y_i^2 - (\sum y_i)^2}}.$$

Ejemplo 1.2. Calcule la desviación estándar total, el error estándar del estimado y el coeficiente de correlación para los datos del ejemplo 1.1.

La desviación estándar es:

$$S_y = \sqrt{\frac{S_t}{n-1}} = \sqrt{\frac{2.468}{5-1}} = 0.78549$$

y el error estándar del estimado es

$$S_{y/x} = \sqrt{\frac{0.06936}{5-2}} = 0.1520.$$

Como $S_{y/x} < S_y$ el modelo de regresión lineal es adecuado. La mejora puede cuantificarse mediante:

$$r^2 = \frac{2.468 - 0.06936}{2.468} = 0.97189$$

o

$$r = 0.98584$$

Los resultados indican que el modelo explicó el 97.189 % de la incertidumbre original.

⁴ $S_t = \sum_{i=1}^n (y_i - \bar{y})^2$

1.2. Programa computacional para la regresión lineal

Es relativamente fácil desarrollar un pseudocódigo para la regresión lineal.

```
1: function REGRESIONLINEAL(x,y,n,a1,a0,syx,r2)
2:   sumx=0: sumxy=0: st=0
3:   sumy=0: sumx2=0: sr=0
4:   for i=1:n do
5:     sumx=sumx+ $x_i$ 
6:     sumy=sumy+ $y_i$ 
7:     sumxy=sumxy+ $x_i*y_i$ 
8:     sumx2=sumx2+ $x_i^2$ 
9:   end for
10:  xm=sumx/n
11:  ym=sumy/n
12:  a1=(n*sumxy-sumx*sumy)/(n*sumx2-sumx*sumx)
13:  a0=ym-a1*xm
14:  for i=1:n do
15:    st=st+ $(y_i - ym)^2$ 
16:    sr=sr+ $(y_i - a1 * x_i - a0)^2$ 
17:  end for
18:  syx=(sr/(n - 2))0.5
19:  r2=(st-sr)/st
20: end function
```

1.3. Linealización de relaciones no lineales

La regresión lineal ofrece una poderosa técnica para ajustar una mejor línea a los datos. Sin embargo, se considera el hecho de que la relación entre las variables dependiente e independiente es lineal. Éste no es siempre el caso, y el primer paso en cualquier análisis de regresión deberá ser graficar e inspeccionar los datos en forma visual, para asegurarnos que sea posible usar un modelo lineal. En algunos casos, las técnicas como la regresión polinomial, que veremos en la siguiente clase, son apropiadas. En otros, se pueden utilizar transformaciones para expresar los datos en una forma que sea compatible con la regresión lineal.

Un ejemplo es el modelo exponencial

$$y = \alpha_1 e^{\beta_1 x}$$

donde α_1 y β_2 son constantes. Este modelo se emplea en muchos campos de la ingeniería para caracterizar cantidades que aumentan (β_1 positivo) o disminuyen (β_1 negativo), a una velocidad que es directamente proporcional a sus propias magnitudes. Como es el caso del crecimiento poblacional o el decaimiento radioactivo.

Otro ejemplo de modelo no lineal es la ecuación de potencias

$$y = \alpha_2 x^{\beta_2}$$

donde α_2 y β_2 son coeficientes constantes. Un tercer modelo no lineal es la ecuación de razón de crecimiento

$$y = \alpha_3 \frac{x}{\beta_3 + x}$$

donde α_3 y β_3 son coeficientes constantes. Este modelo es particularmente adecuado para caracterizar la razón de crecimiento poblacional bajo condiciones limitantes, también representa una relación no lineal entre x y y que se iguala o “satura”, conforme x aumenta.

Hay técnicas de regresión no lineal disponibles para ajustar estas ecuaciones de manera directa a datos experimentales. Sin embargo una alternativa simple consiste en utilizar manipulaciones matemáticas para transformar las ecuaciones en una forma lineal. Después se utiliza regresión simple para ajustar las ecuaciones a los datos.

Por ejemplo $y = \alpha_1 e^{\beta_1 x}$ se linealiza al aplicarle el logaritmo natural obteniendo

$$\ln y = \ln \alpha_1 + \beta_1 x \ln e = \ln \alpha_1 + \beta_1 x.$$

Así, una gráfica de $\ln y$ contra x dará una línea recta con una pendiente β_1 y con una intersección con el eje de coordenadas igual a $\ln \alpha_1$.

La ecuación del modelo $y = \alpha_2 x^{\beta_2}$ es linealizada al aplicarle el logaritmo de base 10 obteniendo

$$\log y = \beta_2 \log x + \log \alpha_2.$$

De este modo, una gráfica de $\log y$ contra $\log x$ da una línea de pendiente β_2 e intersección con el eje de ordenadas $\log \alpha_2$.

La ecuación del modelo de saturación es linealizada al invertirla para obtener:

$$\frac{1}{y} = \frac{\beta_3}{\alpha_3} \frac{1}{x} + \frac{1}{\alpha_3}.$$

De esta forma, una gráfica de $1/y$ contra $1/x$ será lineal, con pendiente β_3/α_3 y una intersección con el eje de las ordenadas $1/\alpha_3$.

En sus formas transformadas, estos modelos pueden usar la regresión lineal para poder evaluar los coeficientes constantes. Después, regresarse a su estado original y usarse para fines predictivos.

Ejemplo 1.3. Determine los parámetros a y b tales que $f(x) = ae^{bx}$ ajuste los siguientes datos.

x	1.2	2.8	4.3	5.4	6.8	7.9
y	7.5	16.1	38.9	67.0	146.6	266.2


El problema es ajustar $\ln(ae^{bx}) = \ln a + bx$ para los datos

x	1.2	2.8	4.3	5.4	6.8	7.9
$z = \ln y$	2.015	2.779	3.661	4.205	4.988	5.584

Ahora nos ocupamos de la regresión lineal, donde los parámetros que se encuentran son $A = \ln a$ y b . Siguiendo los pasos del Ejemplo 1.1, obtenemos (omitiendo algunos de los detalles aritméticos)

$$\begin{aligned} \bar{x} &= \frac{1}{6} \sum x_i = 4.733 & \bar{z} &= \frac{1}{6} \sum z_i = 3.872 \\ b &= \frac{\sum z_i(x_i - \bar{x})}{\sum x_i(x_i - \bar{x})} = \frac{16.716}{31.153} = 0.5366 & A &= \bar{z} - \bar{x}b = 1.3323 \end{aligned}$$

Entonces, $a = e^A = 3.790$ y la función que se ajusta es $f(x) = 3.790e^{0.5366x}$. La gráfica de $f(x)$ y los puntos se muestran en la figura.



2. Ajuste de Formas Lineales

Considere los mínimos cuadrados ajustados a la forma lineal

$$f(x) = a_1 f_1(x) + a_2 f_2(x) + \cdots + a_m f_m(x) = \sum_{j=1}^m a_j f_j(x) \quad (2)$$

donde cada $f_j(x)$ es una función predeterminada de x , llamada una *función base*. Sustituyendo en la ecuación de suma de cuadrados de residuos:

$$S = \sum_{i=1}^n \left[y_i - \sum_{j=1}^m a_j f_j(x_i) \right]^2$$

Entonces las ecuaciones de las derivadas parciales son:

$$\frac{\partial S}{\partial a_k} = -2 \left\{ \sum_{i=1}^n \left[y_i - \sum_{j=1}^m a_j f_j(x_i) \right] f_k(x_i) \right\} = 0, \quad k = 1, 2, \dots, m$$

Dividiendo por (-2) e intercambiando el orden de los sumandos, obtenemos

$$\sum_{j=1}^m \left[\sum_{i=1}^n f_j(x_i) f_k(x_i) \right] a_j = \sum_{i=1}^n f_k(x_i) y_i, \quad k = 1, 2, \dots, m$$

En notación matricial esas ecuaciones son

$$Aa = b$$

donde

$$A_{kj} = \sum_{i=1}^n f_j(x_i) f_k(x_i) \quad b_k = \sum_{i=1}^n f_k(x_i) y_i$$

Estas ecuaciones son conocidas como *ecuaciones normales* del ajuste por mínimos cuadrados, y pueden ser resueltas por cualquiera de los métodos discutidos en la Unidad 3. Note que los coeficientes de dicha matriz es simétrica, esto es, $A_{kj} = A_{jk}$.

3. Regresión Polinomial

En la sección anterior se analizó un procedimiento para obtener la ecuación de una línea recta por medio del criterio de mínimos cuadrados. Sin embargo, en algunos datos exhiben un patrón marcado y son pobremente representados por una línea recta, entonces, una curva podrá ser más adecuada para ajustarse a los datos. Como se logró observar anteriormente, un método para lograr este objetivo es utilizar transformaciones. Otra alternativa es ajustar un polinomio a los datos mediante *regresión polinomial*.

El procedimiento de mínimos cuadrados se puede extender fácilmente al ajuste de datos con un polinomio de grado superior.

Supongamos que ajustamos un polinomio de segundo grado o cuadrático:

$$y = a_0 + a_1x + a_2x^2 + e.$$

En este caso, la suma de los cuadrados de los residuos es:

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1x_i - a_2x_i^2)^2.$$

Obteniendo la derivada respecto a cada uno de los coeficientes desconocidos del polinomio,

$$\begin{aligned}\frac{\partial S_r}{\partial a_0} &= -2 \sum (y_i - a_0 - a_1x_i - a_2x_i^2) \\ \frac{\partial S_r}{\partial a_1} &= -2 \sum ([y_i - a_0 - a_1x_i - a_2x_i^2]x_i) \\ \frac{\partial S_r}{\partial a_2} &= -2 \sum ([y_i - a_0 - a_1x_i - a_2x_i^2]x_i^2)\end{aligned}$$

Estas ecuaciones se igualan a cero y se reordenan para desarrollar el siguiente conjunto de ecuaciones normales:

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{bmatrix}$$

donde todas las sumatorias van desde $i = 1$ hasta n . Observe que las tres ecuaciones anteriores son lineales y tienen tres incógnitas: a_0 , a_1 y a_2 . Los coeficientes de las incógnitas se evalúan de manera directa, a partir de los datos observados.

En este caso, observamos que el problema de determinar un polinomio de segundo grado por mínimos cuadrados es equivalente a resolver un sistema de tres ecuaciones lineales simultáneas. En la Unidad 3, se estudiaron las técnicas para resolver tales ecuaciones.

El caso bidimensional se extiende con facilidad a un polinomio de m -ésimo grado como sigue:

$$y = a_0 + a_1x + a_2x^2 + \cdots + a_mx^m + e.$$

El análisis se puede extender fácilmente a este caso más general. Así, se reconoce que la determinación de los coeficientes de un polinomio de m -ésimo grado es equivalente a resolver

un sistema de $m + 1$ ecuaciones lineales simultáneas. En este caso, el error estándar del estimado se formula como sigue:

$$S_{y/x} = \sqrt{\frac{S_r}{n - (m + 1)}}$$

Esta cantidad se divide entre $n - (m + 1)$, ya que $(m + 1)$ coeficientes obtenidos de los datos, $a_0, a_1, \dots, a_m$, se utilizaron para calcular S_r ; hemos perdido $m + 1$ grados de libertad. Además del error estándar, también se calcula un coeficiente de determinación para la regresión polinomial con la ecuación (1).

Una forma lineal comúnmente usada es una polinomio. Si el grado del polinomio es $m - 1$, tenemos $f(x) = \sum_{j=1}^m a_j x^{j-1}$. Aquí las funciones base son

$$f_j(x) = x^{j-1}, \quad j = 1, 2, \dots, m$$

entonces las ecuaciones normales son:

$$A_{jk} = \sum_{i=1}^n x_i^{j+k-2} \quad b_k = \sum_{i=1}^n x_i^{k-1} y_i$$

o

$$A = \begin{bmatrix} n & \sum x_i & \sum x_i^2 & \cdots & \sum x_i^{m-1} \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \cdots & \sum x_i^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^{m-1} & \sum x_i^m & \sum x_i^{m+1} & \cdots & \sum x_i^{2m-2} \end{bmatrix} \quad b = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \\ \vdots \\ \sum x_i^{m-1} y_i \end{bmatrix}$$

donde $\sum$ esta dado desde $i = 1$ hasta n . Las ecuaciones normales se convierten progresivamente en sistemas mal condicionados a medida que m incrementa. Afortunadamente, esto tiene poca consecuencia práctica, porque solo los polinomios de orden bajo son útiles en el ajuste de curvas. Los polinomios de alto orden no son recomendados, porque tienden a reproducir el ruido inherente a los datos.

Ejemplo 3.1. Emplee regresión no lineal para ajustar una parábola a los datos siguientes:

x	0.2	0.5	0.8	1.2	1.7	2	2.3
y	500	700	1000	1200	2200	2650	3750

A partir de los datos dados,

$$\begin{array}{lll} m = 2 & \sum x_i = 8.7 & \sum x_i^4 = 54.8835 \\ n = 7 & \sum y_i = 12000 & \sum x_i y_i = 20355 \\ \bar{x} = 1.242857 & \sum x_i^2 = 14.55 & \sum x_i^2 y_i = 39358.5 \\ \bar{y} = 1714.285714 & \sum x_i^3 = 27.453 & \end{array}$$

Entonces, las ecuaciones lineales simultáneas son

$$\begin{bmatrix} 7 & 8.7 & 14.55 \\ 8.7 & 14.55 & 27.453 \\ 14.55 & 27.453 & 54.8835 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 12000 \\ 20355 \\ 39358.5 \end{bmatrix}$$

Resolviendo estas ecuaciones con una técnica como la eliminación de Gauss, se tiene $a_0 = 604.0941708$, $a_1 = -233.9608633$ y $a_2 = 674.0068945$. Por lo tanto, la ecuación cuadrática por mínimos cuadrados en este caso es

$$y = 604.0941708 - 233.9608633x + 674.0068945x^2$$


El error de la estimación con base en la regresión polinomial es

$$S_{y/x} = \sqrt{\frac{1412573330}{7-3}} = 18792.10825$$

El coeficiente de determinación es

$$r^2 = \frac{8533571.429 - 90242.96519}{8533571.429} = 0.989424948$$

y el coeficiente de correlación es $r = 0.99469842$. Estos resultados indican que con el modelo se explicó el 98.94 % de la incertidumbre original. Este resultado apoya la conclusión de que la ecuación cuadrática representa un excelente ajuste, como también es evidente en la figura.



3.1. Algoritmo para la regresión polinomial

Un algoritmo para la regresión polinomial se expone a continuación. Observe que la principal tarea es la generación de los coeficientes de las ecuaciones normales. La función *polynFit* calcula los coeficientes de un polinomio de grado $m - 1$ para ajustar n datos por mínimos cuadrados. Para facilitar los cálculos, en términos de n , $\sum x_i$, $\sum x_i^2, \dots, \sum x_i^{2m-2}$ que conforman a la matriz A estos son primeramente guardados en un vector s y luego son insertados en A .

Las ecuaciones normales son resueltas para el vector de coeficientes *coeff* por eliminación Gaussiana con pivoteo. Ya que los elementos de *coeff* que emerge de la solución no están ordenados en el orden usual (los coeficientes de las potencias de x mayores primero), los *coeff* es “girados” al revés antes de retornar el resultado.

```

1 function coeff = polynFit(xData,yData,m)
2 % Retorna los coeficientes del polinomio
3 % a(1)*x^(m-1) + a(2)*x^(m-2) + ... + a(m)
4 % que ajusta los datos por minimos cuadrados.
5 % USAGE: coeff = polynFit(xData,yData,m)
6 % xData = x-coordenadas de los puntos datos.

```

```

7  %yData = y-coordenadas de los puntos datos.
8
9  A = zeros(m); b = zeros(m,1); s = zeros(2*m-1,1); n=length(xData);
10 for j = 1:m
11     b(j) = sum((xData.^(j-1)).*yData);
12 end
13 for j = 1:2*m-1
14     s(j) = sum(xData.^(j-1));
15 end
16 for i = 1:m
17     for j = 1:m
18         A(i,j) = s(i+j-1);
19     end
20 end
21 %Reordenar los coeficientes de forma que
22 %el coeficiente de x^(m-1) este primero
23 coeff = flipdim(gaussPiv(A,b),1);

```

Después de que los coeficientes del polinomio ajustado son calculados, la desviación estándar σ puede ser calculada con la función *stdDev*. La evaluación del polinomio en *stdDev* es realizada por la subfunción *polyEval*.

```

1  function [sigma,r2] = stdDev(coeff,xData,yData)
2  %Retorna la desviacion estandar entre los puntos datos y el
   polinomio
3  %a(1)*x^(m-1) + a(2)*x^(m-2) + ... + a(m)
4  %USAGE: sigma = stdDev(coeff,xData,yData)
5  %coeff = coeficientes del polinomio.
6  %xData = x-coordenadas de los puntos datos.
7  %yData = y-coordenadas de los puntos datos.
8  %Tambien retorna el coeficiente de determinacion r^2 en
   porcentaje
9  %USAGE: [sigma, r2] = stdDev(coeff,xData,yData)
10 m = length(coeff); n = length(xData); sigma = 0;
11 for i =1:n
12     y = polyEval(coeff,xData(i));
13     sigma = sigma + (yData(i) - y)^2;
14 end
15 if nargin > 1; r2 =100*(1-sigma/(var(yData)*(n-1))); end;
16 sigma =sqrt(sigma/(n - m));
17
18 function y = polyEval(coeff,x)
19 %Retorna el valor del polinomio en x.
20 m = length(coeff);
21 y = coeff(1);
22 for j = 1:m-1; y = y*x + coeff(j+1); end;

```

Ejemplo 3.2. Escribe un programa que ajuste un polinomio para un grado k arbitrario para los puntos datos mostrados abajo. Use el programa para determinar k que mejor se ajuste a estos datos por mínimos cuadrados

x	-0.04	0.93	1.95	2.90	3.83	5.00
y	-8.66	-6.44	-4.36	-3.27	-0.88	0.87
x	5.98	7.05	8.21	9.08	10.09	
y	3.31	4.63	6.19	7.40	8.85	

Solución. El siguiente programa muestra para k . Ejecución es terminada al presionar “enter”

```

1  %Ejemplo 3.2 (Ajuste Polinomial)
2  xData = [-0.04,0.93,1.95,2.90,3.83,5.0,...
3  5.98,7.05,8.21,9.08,10.09]';
4  yData = [-8.66,-6.44,-4.36,-3.27,-0.88,0.87,...
5  3.31,4.63,6.19,7.4,8.85]';
6  format short e; format compact;
7  while 1
8      k = input('Grado del polinomio = ');
9      if isempty(k) %Loop es terminado
10         fprintf('Hecho\n') %al presionar ''enter''
11         break
12     end
13     coeff = polynFit(xData,yData,k+1)
14     sigma = stdDev(coeff,xData,yData)
15     fprintf('\n')
16 end

```

Los resultados son:

```

1  Grado del polinomio = 1
2  coeff =
3      1.7286e+00
4      -7.9453e+00
5  sigma =
6      5.1128e-01
7
8  Grado del polinomio = 2
9  coeff =
10     -4.1971e-02
11      2.1512e+00
12     -8.5701e+00
13  sigma =
14      3.1099e-01
15
16 Grado del polinomio = 3
17 coeff =
18     -2.9852e-03
19      2.8845e-03
20      1.9810e+00
21     -8.4660e+00


```

```

22 sigma =
23     3.1948e-01
24
25 Grado del polinomio =
26 Hecho

```

Debido a que la cuadrática $f(x) = -0.041971x^2 + 2.1512x - 8.5701$ produce la menor desviación estándar, puede ser considerada como la “mejor” para ajustar a los datos. Pero advertimos que la desviación estándar no es una medida infalible de la bondad del ajuste. Es siempre buena idea graficar los puntos datos y $f(x)$ antes de hacer una decisión final. La gráfica de nuestros datos indica que la cuadrática es de hecho una razonable opción para el ajuste.



4. Regresión Lineal Múltiple

Una extensión útil de la regresión lineal es el caso en el que y es una función lineal de dos o más variables independientes. Por ejemplo, y podría ser una función lineal de x_1 y x_2 , como en

$$y = a_0 + a_1x_1 + a_2x_2 + e.$$

En particular tal ecuación es útil cuando se ajustan datos experimentales donde la variable sujeta a estudio es una función de otras dos variables. En este caso dimensional, la “línea” de regresión se convierte en un “plano”.

Las ecuaciones normales en este caso quedan representadas como:

$$\begin{bmatrix} n & \sum x_{1_i} & \sum x_{2_i} \\ \sum x_{1_i} & \sum x_{1_i}^2 & \sum x_{1_i}x_{2_i} \\ \sum x_{2_i} & \sum x_{1_i}x_{2_i} & \sum x_{2_i}^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_{1_i}y_i \\ \sum x_{2_i}y_i \end{bmatrix}$$

Problemas Propuestos

En los siguientes problemas realice lo pedido y además una gráfica de los datos y la curva de regresión.

Problema 4.1. Utilice regresión por mínimos cuadrados para ajustar una línea recta a

x	0	2	4	6	9	11	12	15	17	19
y	5	6	7	6	9	8	7	10	12	12

Además de la pendiente y la intersección, calcule el error estándar de la estimación y el coeficiente de correlación. Después repita el problema, pero ahora efectúe la regresión de x versus y , es decir, intercambie las variables. Interprete sus resultados.

Problema 4.2. Utilice regresión por mínimos cuadrados para ajustar una línea recta a

x	6	7	11	15	17	21	23	29	29	37	39
y	29	21	29	14	21	15	7	7	13	0	3

Además de la pendiente y la intersección, calcule el error estándar de la estimación y el coeficiente de correlación. ¿Si otra persona hiciera una medición adicional de $x = 10, y = 10$, usted pensaría, con base en una evaluación visual y el error estándar, que la medición era válida o inválida? Justifique su conclusión.

Problema 4.3. Con el mismo enfoque que se empleó para obtener las ecuaciones del modelo de regresión lineal simple, obtenga el ajuste por mínimos cuadrados del modelo siguiente:

$$y = a_1x + e$$

Es decir, determine la pendiente que resulta en el ajuste por mínimos cuadrados para una línea recta con intersección en el origen. Ajuste los datos siguientes con dicho modelo:

x	2	4	6	7	10	11	14	17	20
y	1	2	5	2	8	7	6	9	12

Problema 4.4. Ajuste los datos siguientes con a) un modelo de tasa de crecimiento de saturación, b) una ecuación de potencias.

x	0.75	2	3	4	6	8	8.5
y	1.2	1.95	2	2.4	2.4	2.7	2.6

Problema 4.5. Ajuste los datos siguientes con el modelo de potencias ($y = ax^b$). Use la ecuación de potencias resultante para hacer el pronóstico de y en $x = 9$.

x	2.5	3.5	5	6	7.5	10	12.5	15	17.5	20
y	13	11	8.5	8.2	7	6.2	5.2	4.8	4.6	4.3

Problema 4.6. Ajuste un modelo exponencial a

x	0.4	0.8	1.2	1.6	2	2.3
y	800	975	1500	1950	2900	3600

Problema 4.7. Pruebe que la línea recta obtenida por ajuste de mínimos cuadrados siempre pasa por el punto $(\bar{x}, \bar{y})$.

Problema 4.8. Ajuste una ecuación cúbica a los datos siguientes:

x	3	4	5	7	8	9	11	12
y	1.6	3.6	4.4	3.4	2.2	2.8	3.8	4.6

Además de los coeficientes, determine r^2 y $S_{y/x}$.

Problema 4.9. Use regresión lineal múltiple para ajustar

x_1	0	1	1	2	2	3	3	4	4
x_2	0	1	2	1	2	1	2	1	2
y	15.1	17.9	12.7	25.6	20.5	35.1	29.7	45.4	40.2

Calcule los coeficientes, el error estándar de la estimación y el coeficiente de determinación.

Funciones MATLAB

$a = \text{polyfit}(xData, yData, m)$ retorna los coeficientes de un polinomio of grado m que ajusta los datos por mínimos cuadrados.

$y = \text{polyval}(a, x)$ evalúa un polinomio definido por sus coeficientes en el punto x . Si x es un array, y es calculado para todos los elementos de x .

$s = \text{std}(x)$ retorna la desviación estándar de los elementos de un array x . Si x es una matriz, s es calculado para cada columna de x .

$\bar{x} = \text{mean}(x)$ calcula la media de los elementos de x . Si x es una matriz, s es calculado para cada columna de x .

Las formas lineales pueden ser ajustadas a los datos por las fórmulas descritas en las secciones anteriores

$$Fa = y$$

y resolviéndolas con el comando $a = F \backslash y$ (recuerde que para las ecuaciones sobre determinadas, el operador barra invertida devuelve la solución de mínimos cuadrados). Aquí una ilustración, para ajustar

$$f(x) = a_1 + a_2 e^x + a_3 x e^{-x}$$

a los datos:

```

1 xData = [1.2; 2.8; 4.3; 5.4; 6.8; 7.0];
2 yData = [7.5; 16.1; 38.9; 67.0; 146.6; 266.2];
3 F = ones(length(xData), 3);
4 F(:, 2) = exp(xData(:));
5 F(:, 3) = xData(:) .* exp(-xData(:));
6 a = F \ yData

```